

TURBINE STRESS PREDICTION MODEL

작성일 | 2026년 7월 27일
대상 설비 | 당진화력 1~4호기
모델 유형 | 공정분석 기반 예측 모델


목차

1. 도메인 배경 및 공정 이해	4
1.1. 대상 설비 및 공정 메커니즘 이해	4
1.2. 주요 공정 변수 및 용어 정의	6
2. 개발 배경 및 목적	6
2.1. 터빈 노후화	6
2.2. 현장 예측 모델의 신뢰성 및 실효성 한계	7
2.3. 개발 목적	7
3. 데이터 현황	8
3.1. 데이터 개요	8
3.2. 호기별 기동 데이터	8
3.3. TBN STRESS 패턴 분석	8
4. 모델 구조	9
4.1. 예측 모델	9
5. 파생변수 설계	9
5.1. 조합형 파생변수	9
직접적인 응력 원인 포착	9
선형 모델의 비선형 표현력 보강	10
열응력+기계적 응력의 동시 작용 모델링	10
5.2. 제곱항 (Polynomial Feature)	10
5.3. Lag / Rolling 통계	11
6. 데이터셋 분할	11
7. 성능 평가 결과	11
7.1. 전체 성능 요약	11
7.1.1. HP TBN SURFACE STRESS	11
7.1.2. HP TBN BORE STRESS	12
7.1.3. RH TBN INLET SURFACE STRESS	13

7.1.4.	RH TBN INLET BORE STRESS.....	14
7.1.5.	RH TBN OUTLET SURFACE STRESS.....	15
7.1.6.	RH TBN OUTLET BORE STRESS	16
7.2.	결과 해석.....	17

1. 도메인 배경 및 공정 이해

1.1. 대상 설비 및 공정 메커니즘 이해



Step 1. 고압 터빈 유입 차단 및 바이패스 정렬

보일러에서 생산된 고온·고압의 메인 증기(Main Steam)가 고압 터빈으로 들어가지 못하도록 고압 조절밸브를 폐쇄 상태로 유지한다.

갈 곳이 없어진 메인 증기는 열려 있는 HP Bypass Valve를 통해 안전하게 우회하여 저온 재열 배관(CRH)으로 이동한다.

Step 2. 냉각 증기(Cooling Steam) 분기 및 고압 터빈 역류

저온 재열 배관(CRH)으로 넘어온 증기 중 대량의 분류는 보일러의 재열기(Reheater)로 들어가고, 일부 증기가 냉각용으로 분기된다.

이 냉각 증기는 열려 있는 역류 밸브(RFV)를 통과한 뒤, 고압 터빈의 출구 쪽으로 강제 유입된다.

Step 3. 고압 터빈 내부 냉각 및 배출

출구로 들어온 냉각 증기는 원래 설계된 방향과 반대인 출구→내부→입구 방향으로 거꾸로 흐르며, 터빈 날개의 고속 회전으로 인해 발생하는 마찰열을 식혀준다.


냉각을 마치고 고압 터빈 입구 쪽으로 빠져나온 증기는 열려 있는 통풍 밸브를 거쳐 복수기로 안전하게 배출된다.

Step 4. 재열 증기를 통한 중/저압 터빈 구동

Step 2에서 재열기로 들어갔던 메인 증기는 뜨겁게 가열되어 고온 재열 증기(Hot Reheat)가 된다.

이 증기가 중압 터빈과 저압 터빈으로 유입되면서 본격적으로 터빈 축을 회전시키고 초기 부하를 감당하게 된다.

Forward Flow Mode



Step 1. 냉각 계통 차단 및 바이패스 폐쇄

터빈 부하가 기준치에 도달하면, 기존에 열어 있던 역류 밸브(RFV)와 고압 터빈 입구 쪽의 통풍 밸브(VV)를 닫아 역류 냉각 흐름을 차단한다.

이와 동시에 HP Bypass Valve를 폐쇄하여 증기가 고압 터빈을 우회하지 못하도록 정렬한다.

Step 2. 고압 조절밸브 개방 및 고압 터빈 정방향 구동

닫혀 있던 고압 조절밸브를 서서히 열어, 보일러의 메인 증기를 고압 터빈 내부로 유입시킨다.

유입된 증기는 고압 터빈의 입구→내부→출구 방향으로 흐르며 팽창하여 고압 터빈을 본격적으로 구동시킨다.

Step 3. 고압 터빈 배기(Cold Reheat)의 재열기 유입

고압 터빈을 돌리고 정상적으로 빠져나온 배기 증기는 저온 재열 증기가 되어 저온 재열 배관을 통해 보일러의 재열기로 이동한다.

Step 4. 터빈 연계 및 정상 출력 운전

재열기에서 가열되어 나온 고온 재열 증기가 중압 터빈과 저압 터빈으로 들어가 차례로 돌린다.

이로써, 고·중·저압 터빈이 모두 정방향 흐름으로 연계되어, 본격적으로 전기를 생산하는 정상 부하 운전 단계로 진입한다.

1.2. 주요 공정 변수 및 용어 정의

용어 (Term)	의미 (Definition)
CVR(Control Valve Rate)	주증기 제어밸브의 개도율(%)
TURBINE SPEED	터빈 로터의 분당 회전수(RPM)
CRH 증기 온도	HP 터빈 출구에서 재열기로 향하는 Cold Reheat 증기의 온도
STEAM CHEST PRESSURE	터빈이 실제로 받는 증기 압력 (Steam Chest: 제어밸브와 HP 터빈 입구 사이에 위치한 증기를 일시적으로 모아두는 챔버)
주증기 압력	보일러에서 HP 터빈 유입되는 주증기 압력
주증기 온도	보일러에서 HP 터빈 입구로 유입되는 주증기 온도
HP TBN ROTOR BORE METAL TEMP	HP 터빈 로터 보어 금속 온도
1단 금속 온도	HP 터빈 1단 블레이드 부근 금속 표면 온도
재열증기 압력	재열기를 통과한 후 IP(RH) 터빈 입구로 유입되는 재열증기의 압력
재열증기 온도	RH TBN INLET 지점의 재열증기 온도
RH TBN ROTOR BORE METAL TEMP	RH 터빈 로터 보어 금속 온도
REHEAT BOWL INNER SURFACE TEMP	RH TBN INLET 직후 로터 표면이 재열 증기에 노출되는 지점의 온도

2. 개발 배경 및 목적

2.1. 터빈 노후화

당진화력 1~4호기 터빈은 준공 이후 시간 경과에 따른 노후화가 지속적으로 진행 중이다. 노후화된 터빈 금속은 반복적인 열 사이클에 의한 피로 누적으로 인해 동일한 열응력 조건에서도 손상 위험이 증가한다. 따라서 설비 노후화가 진행되는 상황에서 정밀한 열응력 관리의 중요성은 더욱 커지고 있다.

2.2. 현장 예측 모델의 신뢰성 및 실효성 한계

기동·정지 시 터빈 열응력 최소화를 위해 현재 현장에서 운용 중인 미래 예측 데이터 기반 제어 방식은 다음과 같은 치명적인 한계점을 가지고 있어 실질적인 운전 가이드로 활용하기 어렵다.

- **낮은 예측 정확도:** 현재 유입되는 예측 데이터의 오차 범위가 너무 커 실제 현장 상태를 반영하지 못하며, 신뢰성이 낮아 제어 지표로 활용할 수 없다.
- **예측 시점의 불명확성:** 제공되는 예측값이 '몇 분 후'의 시점인지 알 수 없어, 선제적 대응이 핵심인 열응력 관리에서 실효성이 떨어진다.
- **사전 제어의 한계:** 예측값의 정확도와 출력 시점이 불확실하여, 터빈 손상을 방지하기 위한 능동적인 사전 제어를 수행하기 어렵다.

이에 따라 예측 시점을 명확히 규명하고, 실제 공정 데이터 기반으로 정확도를 대폭 개선한 '미래 시점이 명확한 열응력 예측 모델'로의 전환이 필요하다.

2.3. 개발 목적

1~5분 단기 예측 및 선제 운전 지원

정확한 시점 정보가 없던 기존 방식에서 벗어나, 1분 뒤부터 5분 뒤까지의 열응력 변화 추이를 1분 단위로 세분화하여 예측한다. 이를 통해 운전원이 단기 미래의 열응력 변화를 정밀하게 예측·인지하고, 급격한 응력 상승에 선제적으로 대응할 수 있는 운전 가이드를 제공한다.

Multi-horizon 기반의 시계열 예측 신뢰성 확보

단일 시점 예측의 한계를 넘어, 하나의 모델이 미래 1분~5분 구간의 열응력 변화 추이를 동시에 출력하는 Multi-horizon(다중 시점) 예측 기법을 구축한다. 실제 공정 데이터 기반으로 단기 미래의 연속적인 시계열 변동 패턴을 정밀하게 학습함으로써 예측 오차를 최소화하고 지표의 신뢰성을 확보한다.

시간 단위 모호성 제거를 통한 의사결정 신뢰도 향상

유입 데이터의 예측 시간 불확실성을 완전히 해소하여, 화면에 표시되는 예측값이 '정확히 몇 분 뒤의 상태'인지를 운전원에게 명확히 제시한다. 시간 정보가 매핑된 직관적인 데이터 제공을 통해, 기동·정지 시 운전원이 확신을 가지고 안전한 제어 의사결정을 내릴 수 있도록 지원한다.

3. 데이터 현황

3.1. 데이터 개요

항목	내용
대상 호기	1~4호기
데이터 기간	2023~2025년 기동 데이터
샘플링 주기	1분 단위 (평균값 사용)
데이터 유형	기동(Start-up) 데이터


3.2. 호기별 기동 데이터

호기	2023년	2024년	2025년	비고
1호기	5개	23개	11개	-
2호기	12개	0개	2개	데이터 부족
3호기	1개	0개	7개	데이터 부족
4호기	15개	18개	13개	-

2호기와 3호기는 타 호기 대비 기동 데이터가 부족하며, 모델 학습 시 편향 가능성이 있으므로 결과 해석 시 유의가 필요하다.

3.3. TBN STRESS 패턴 분석

탐색적 데이터 분석(EDA) 결과, SURFACE STRESS와 BORE STRESS는 서로 다른 시간적 패턴을 보였다.



- **SURFACE STRESS:** 운전 조건 변화에 즉각 반응하여 파형이 첨예하게 나타남
- **BORE STRESS:** 로터 내부 열전달 지연(Thermal Lag)으로 인해 변화가 부드럽고 완만함

4. 모델 구조

4.1. 예측 모델

구분	Naive	LightGBM
정의	별도의 알고리즘 학습 없이, 현재 시점의 값이 미래에도 그대로 유지될 것이라고 가정하는 가장 기초적인 예측 방식	실제 공정 데이터의 패턴을 학습하여, 미래 1~5분 뒤의 열응력 변화 추이를 동시에 일관되게 예측하는 다중 시점 머신러닝 모델
특징	- 연산이나 분석 로직이 없음 - 시계열의 자기상관성만을 이용 - 미래 시점과 상관없이 동일한 현재 값 출력	- 여러 운전 변수 간의 복잡한 비선형 관계를 학습 - 트리 기반 알고리즘으로 대용량 데이터 전처리 및 학습 속도가 빠름
장점	- 모델 구축 비용 및 시스템 부하가 0에 수렴 - 누구나 직관적으로 이해하기 쉬움 - 초단기 예측에서는 생각보다 강력한 기준점 역할을 함	- 미래 시점별 변동 추이를 정밀하게 예측 가능 - 시점이 명확히 매핑되어 운전원의 선제적 제어 가시성 확보 - 시계열 오차를 최소화하여 제어 지표로서의 실효성 높음
한계	- 예측시점이 멀어질수록 오차가 급격히 증가함 - 선제적 대응이 불가능하여 사후 조치만 가능	- 모델 학습을 위해 양질의 과거 운전 이력 데이터가 필수적임 - 주기적인 데이터 업데이트 및 모델 재학습 관리가 필요함

5. 파생변수 설계

5.1. 조합형 파생변수

직접적인 응력 원인 포착

열응력의 가장 직접적인 물리 인자를 수식으로 표현한 변수들이다.

① HP_delta_T_rate |보어온도 - 1단금속온도|

내부(보어)와 외부(표면)의 온도 차이가 클수록 열팽창 불균형으로 인한 응력이 커지므로,

가장 직접적인 응력 원인 변수이다.

② HP_avg_temp $(1단금속온도 + 보어온도)/2$

현재 로터의 전반적인 열 레벨을 나타내며, 동일한 온도 차라도 고온 영역에서 더 큰 응력이 발생할 수 있어 보정 역할을 한다.

③ $HP_Bore_Temp_Rate$ $보어온도.diff()$

온도 변화 속도가 빠를수록 과도(transient) 열응력이 증가한다.

선형 모델의 비선형 표현력 보강

두 변수의 곱으로 선형 모델이 포착하지 못하는 비선형 상호작용을 학습할 수 있도록 한다.

① $HP_Surface_Bore_Diff_x_Temp$ $|보어온도 - 1단금속온도| \times 1단금속온도$

표면 온도가 높을수록 동일한 온도 차에 대한 열응력 영향이 비선형적으로 커진다.

② $Metal_x_Bore$ $1단금속온도 \times 보어온도$

두 온도가 동시에 높을 때 응력 패턴이 단순 선형합과 달라지는 상호작용을 포착한다.

열응력+기계적 응력의 동시 작용 모델링

① $RPM_x_dT_Steam_Bore$ $RPM \times (주증기온도 - 보어온도)$

주증기와 보어 간 온도 차가 클수록 로터 표면의 열 충격이 커지며, 여기에 RPM에 의한 원심 하중이 더해질 때 응력이 복합적으로 증가한다.

② $RPM_x_dT_Metal_Bore$ $RPM \times |보어온도 - 1단금속온도|$

고속 회전 중 단면 온도 구배까지 클 경우 가장 위험한 조건이 되며, 고 교호항이 그 복합 리스크를 담는다.

③ RPM_x_Metal $RPM \times 1단금속온도$

금속 강도는 고온일수록 저하되므로, 동일한 원심력도 더 큰 상대 응력을 유발한다. 해당 파생변수는 재료 강도 열화를 간접적으로 반영한다.

5.2. 제곱항 (Polynomial Feature)

선정된 원시 컬럼 전체에 제곱항을 적용하여 고온·고속 영역에서의 비선형 응답을 반영하였다.

5.3. Lag / Rolling 통계

최대 30스텝(30분) lag와 window 크기 10/30의 rolling 통계를 적용하였다. 이를 통해 단일 시점 센서 값만으로는 설명되지 않는 열관성, 운전 이력, 시계열 인과성을 데이터 누수 없이 반영하였다.

6. 데이터셋 분할


학습데이터는 2023~2024년의 전 호기 기동 데이터 총 74개로 구성하였으며, 다양한 기동 패턴 학습 및 최적 가중치 도출을 목적으로 한다.

평가 데이터는 2025년의 전 호기 기동 데이터 33개를 사용하였으며, 학습에 포함되지 않은 미노출 데이터로 모델의 일반화 성능을 평가한다. 학습 데이터와 동일한 전처리 기준을 적용하였다.

7. 성능 평가 결과

7.1. 전체 성능 요약

7.1.1. HP TBN SURFACE STRESS




예측 시점 (Horizon)	평가 모델	MAE	RMSE	R ²
t+1분	Naive	0.6820	1.6293	0.9827
	LightGBM	0.4481	0.9738	0.9937
t+2분	Naive	1.1925	2.7999	0.9500
	LightGBM	0.8536	1.8945	0.9768

t+3분	Naive	1.6051	3.7023	0.9134
	LightGBM	1.1630	2.5711	0.9579
t+4분	Naive	1.9315	4.4178	0.8779
	LightGBM	1.3944	3.0606	0.9407
t+5분	Naive	2.1961	5.0010	0.8435
	LightGBM	1.5836	3.4579	0.9250

7.1.2. HP TBN BORE STRESS


5-Minute Ahead Prediction Results of Proposed Model



예측 시점 (Horizon)	평가 모델	MAE	RMSE	R ²
t+1분	Naive	0.1711	0.3655	0.9991
	LightGBM	0.0399	0.0752	1.0000
t+2분	Naive	0.3365	0.7147	0.9965
	LightGBM	0.0883	0.1682	0.9998
t+3분	Naive	0.4943	1.0499	0.9925
	LightGBM	0.1550	0.3026	0.9994
t+4분	Naive	0.6443	1.3694	0.9873
	LightGBM	0.2327	0.4537	0.9985
t+5분	Naive	0.7861	1.6729	0.9811
	LightGBM	0.3148	0.6078	0.9974

7.1.3. RH TBN INLET SURFACE STRESS


5-Minute Ahead Prediction Results of Proposed Model



예측 시점 (Horizon)	평가 모델	MAE	RMSE	R ²
t+1분	Naive	0.2577	0.7517	0.9973
	LightGBM	0.0874	0.3580	0.9994
t+2분	Naive	0.5041	1.3491	0.9915
	LightGBM	0.1581	0.3203	0.9980
t+3분	Naive	0.7463	1.8732	0.9839
	LightGBM	0.2427	0.8768	0.9960
t+4분	Naive	0.9826	2.3566	0.9749
	LightGBM	0.3316	1.0902	0.9943
t+5분	Naive	1.2127	2.8122	0.9647
	LightGBM	0.4321	1.2964	0.9923

7.1.4. RH TBN INLET BORE STRESS


5-Minute Ahead Prediction Results of Proposed Model



예측 시점 (Horizon)	평가 모델	MAE	RMSE	R ²
t+1분	Naive	0.1636	0.3403	0.9996
	LightGBM	0.0319	0.0613	1.0000
t+2분	Naive	0.3266	0.6713	0.9986
	LightGBM	0.0499	0.0941	1.0000
t+3분	Naive	0.4889	1.0003	0.9968
	LightGBM	0.0675	0.1277	0.9999
t+4분	Naive	0.6500	1.3271	0.9944
	LightGBM	0.0890	0.1709	0.9999
t+5분	Naive	0.8098	1.6513	0.9914
	LightGBM	0.1155	0.2223	0.9998

7.1.5. RH TBN OUTLET SURFACE STRESS


5-Minute Ahead Prediction Results of Proposed Model



예측 시점 (Horizon)	평가 모델	MAE	RMSE	R ²
t+1분	Naive	0.2577	0.7506	0.9973
	LightGBM	0.0874	0.3570	0.9994
t+2분	Naive	0.5041	1.3484	0.9915
	LightGBM	0.1600	0.6285	0.9980
t+3분	Naive	0.7463	1.8728	0.9839
	LightGBM	0.2425	0.8723	0.9961
t+4분	Naive	0.9826	2.3563	0.9749
	LightGBM	0.3325	1.0887	0.9943
t+5분	Naive	1.2127	2.8119	0.9647
	LightGBM	0.4321	1.2929	0.9923

7.1.6. RH TBN OUTLET BORE STRESS

5-Minute Ahead Prediction Results of Proposed Model



예측 시점 (Horizon)	평가 모델	MAE	RMSE	R ²
t+1분	Naive	0.1636	0.3404	0.9996
	LightGBM	0.0318	0.0618	1.0000
t+2분	Naive	0.3267	0.6715	0.9986
	LightGBM	0.0498	0.0951	1.0000
t+3분	Naive	0.4890	1.0005	0.9968
	LightGBM	0.0673	0.1282	0.9999
t+4분	Naive	0.6501	1.3274	0.9944
	LightGBM	0.0889	0.1707	0.9999
t+5분	Naive	0.8098	1.6515	0.9914
	LightGBM	0.1159	0.2226	0.9998

7.2. 결과 해석

다중 시점(Multi-horizon) 예측 성능 평가 결과, 제안된 LightGBM 모델은 1분 뒤부터 가장 먼 시점인 5분 뒤 예측에 이르기까지 일관되게 높은 결정계수(R^2)와 낮은 절대오차(MAE)를 기록하며 실제 열응력 변화 추이를 정밀하게 추종하였다. 이는 단편적인 특정 시점의 결과만을 맞추는 것이 아니라, 단일 모델이 미래 1~5분 구간의 연속적인 시계열 변동 패턴 자체를 효과적으로 구조화하여 학습했음을 입증한다. 결과적으로 본 모델을 현장 운전원에게 최대 5분의 명확한 선제적 대응 시간(Lead Time)을 안정적으로 보장함으로써, 기존 시스템의 시점 모호성으로 인한 의사결정 지연을 해소하고 데이터 중심의 능동적인 터빈 기동 최적화를 가능하게 했다.